LABORATUVAR 7 · PANEL BEAM SAW · Ahşap Ebatlama + Robotik İstifleme

AI Safety Challenge

Çıktı: AI Fail-Safe Decision

Ad Soyad | Grup | Tarih

Kavram — Prediction ≠ Safety: Yapay zekâ bir karar üretir; güvenliği garanti eden mimari YZ'nin dışında tanımlanmalıdır. **Araçlar:** fail-safe · human override · monitoring · confidence threshold · fallback.

Senaryo: Ebatlama hattına YZ'li görsel kontrol ve robotik istifleme için YZ'li parça tanıma eklenmesi planlanıyor — proje aşaması değerlendirmesi yapıyorsunuz.

Kamera → **YZ Modeli** → OK / RED → Robot istif / ret → Hat hızı

Görev — üç başarısızlıkta güvenli davranış

1. Model yanlış sınıflandırdı: Kusurlu parçaya OK verdi. Sistem ne yapmalı? İkinci kontrol / insan onayı var mı?

   Evet, olmalı. Ölçü ve kusur kontrolü için bağımsız bir ikinci kontrol (lazer ölçüm veya kural tabanlı ikinci sensör) ve istif sonunda rastgele numuneyle insan onayı eklenir; kaçan hatalı OK oranı izlenir, sınır aşılırsa hat yavaşlar ya da durur. Robotun tutma ve vakum izleme (SF3) ile alan tarayıcı (SF4) fonksiyonları YZ'den bağımsız çalışır, panel düşmesini YZ kararı belirlemez.

2. Girdi manipüle edildi: Kamera verisi bozuk/sahte. Nasıl fark edilir? Şüpheli girdide ne yapılır?

   Kare akışı kontrol edilir (donma, tekrar eden kare, zaman damgası); her N panelde bilinen referans parça gösterilir; kamera sonucu enkoder, ölçüm sensörü ve vakum basıncıyla çapraz doğrulanır. Şüpheli girdide parça OK sayılmaz, RED'e ayrılır, robot güvenli duruşa geçer, operatör uyarılır ve olay kaydedilir.

3. Confidence düştü: Model emin değilim diyor. Eşik ne olmalı? Altında: dur / insana sor / fallback?

   Örnek eşik (gerçek değer pilot verisiyle belirlenir): %90 üstü otomatik karar, %70–90 arası insana sor, %70 altı fallback (parça RED'e ayrılır, elle istif). Art arda düşük güven görülürse hat durdurulur. Yanlış istifte panel düşme riski olduğu için eşik sıkı seçilir.

Karar tablosu — AI Fail-Safe Decision

Başarısızlık	Tanımladığınız güvenli davranış (hangi kavramla?)
Model yanlış sınıflandırdı	Bağımsız ikinci kontrol + numune ile insan onayı; hatalı OK oranı izlenir; robot emniyeti YZ'den bağımsız (**human override, monitoring**).
Girdi manipüle edildi	Şüpheli girdi RED sayılır, robot güvenli duruşa geçer, olay kaydedilir (**monitoring, fail-safe**).
Confidence düştü	Eşik altında insana sor, çok düşükse elle istif, art arda düşükse durdur (**confidence threshold, fallback**).

Bu föyün çıktısı **AI Fail-Safe Decision** → Evidence Pack **EP 03 + EP 15** başlığına oturur.