AI Safety Challenge

Çıktı: AI Fail-Safe Decision

Ad Soyad | Grup | Tarih

Kavram — Prediction ≠ Safety: Yapay zekâ bir karar üretir; güvenliği garanti eden mimari YZ'nin dışında tanımlanmalıdır. **Araçlar:** fail-safe · human override · monitoring · confidence threshold · fallback.

Senaryo: PaketPro'ya YZ'li görsel paket kontrolü eklenmesi planlanıyor — proje aşaması değerlendirmesi yapıyorsunuz.



Görev — üç başarısızlıkta güvenli davranış

1. Model yanlış sınıflandırdı: Kusurlu parçaya OK verdi. Sistem ne yapmalı? İkinci kontrol / insan onayı var mı?
   Evet, olmalı. YZ kararı tek başına güvenilmez: bağımsız bir ikinci kontrol (kural tabanlı ölçüm veya ikinci sensör) ve hat sonunda rastgele numuneyle insan onayı eklenir. Kaçan hatalı OK oranı izlenir, sınır aşılırsa hat yavaşlatılır ya da durdurulur. YZ'nin kararı çene/bıçak bölgesindeki emniyet zincirini (ışık perdesi → Safety PLC → STO) hiçbir şekilde etkilemez.

2. Girdi manipüle edildi: Kamera verisi bozuk/sahte. Nasıl fark edilir? Şüpheli girdide ne yapılır?
   Kare akışı kontrol edilir (donma, tekrar eden kare, zaman damgası, bozuk görüntü); her N karede bilinen referans parça gösterilir; bant enkoderi ve parça sensörüyle çapraz doğrulama yapılır. Şüpheli girdide parça OK sayılmaz: RED'e ayrılır, hat yavaşlar ya da durur, operatör uyarılır ve olay kaydedilir.

3. Confidence düştü: Model emin değilim diyor. Eşik ne olmalı? Altında: dur / insana sor / fallback?
   Örnek eşik (gerçek değer pilot verisiyle belirlenir): %90 üstü otomatik karar, %70–90 arası insana sor, %70 altı fallback (parça RED'e ayrılır, elle kontrol). Art arda düşük güven görülürse hat durdurulur. Kusur kaçırmanın bedeli yüksek olduğu için eşik sıkı seçilir.

Karar tablosu — AI Fail-Safe Decision

Başarısızlık	Tanımladığınız güvenli davranış (hangi kavramla?)
Model yanlış sınıflandırdı	Bağımsız ikinci kontrol + numune ile insan onayı; hatalı OK oranı izlenir (**human override, monitoring**).
Girdi manipüle edildi	Şüpheli girdi RED sayılır, hat yavaşlar ya da durur, olay kaydedilir (**monitoring, fail-safe**).
Confidence düştü	Eşik altında insana sor, çok düşükse elle kontrol, art arda düşükse durdur (**confidence threshold, fallback**).

Bu föyün çıktısı **AI Fail-Safe Decision** → Evidence Pack **EP 03 + EP 15** başlığına oturur.