LABORATUVAR 7 · GENEL SÜRÜM · Şişeleme Hattı

AI Safety Challenge

Çıktı: AI Fail-Safe Decision

Ad Soyad	Grup	Tarih

Kavram — Prediction ≠ Safety: Yapay zekâ bir karar üretir; güvenliği garanti eden mimari YZ'nin **dışında** tanımlanmalıdır.
Araçlar: fail-safe · human override · monitoring · confidence threshold · fallback.

Kamera → YZ Modeli → OK / RED → Parametre → Robot

Görev — üç başarısızlıkta güvenli davranış

1. **Model yanlış sınıflandırdı:** Kusurlu parçaya OK verdi. Sistem ne yapmalı? İkinci kontrol / insan onayı var mı?

   YZ kararı tek başına geçerli sayılmaz: ikinci bağımsız kontrol (seviye/ağırlık sensörü, periyodik numune kontrolü) yapılır. Kritik kusur sınıflarında insan onayı istenir. Robotun emniyeti YZ'den bağımsız olarak Safety PLC'de kalır; parametreler güvenli sınırların dışına çıkamaz.

2. **Girdi manipüle edildi:** Kamera verisi bozuk/sahte. Nasıl fark edilir? Şüpheli girdide ne yapılır?

   Fark etme: donmuş kare, zaman damgası, parlaklık/odak, kamera sağlık sinyali ve beklenmeyen dağılımlar izlenir (monitoring). Şüpheli girdide ürün RED/karantinaya ayrılır, alarm verilir, operatör bilgilendirilir; YZ çıktısı robota iletilmez (fail-safe).

3. **Confidence düştü:** Model "emin değilim" diyor. Eşik ne olmalı? Altında: dur / insana sor / fallback?

   Eşik, risk analizine göre belirlenir (örn. %95). Altında: ürün otomatik olarak karantina hattına ayrılır (fallback) ve operatör karar verir (human override). Düşük güven tekrarlıyorsa hat yavaşlatılır veya durdurulur.

Karar tablosu — AI Fail-Safe Decision

Başarısızlık	Tanımladığınız güvenli davranış (hangi kavramla?)
Model yanlış sınıflandırdı	İkinci bağımsız kontrol + numune denetimi, kritik kusurda insan onayı → monitoring / human override
Girdi manipüle edildi	Girdi doğrulama; şüphelide ürün RED, alarm, robota çıktı gitmez → monitoring / fail-safe
Confidence düştü	Eşik altı ürün karantinaya, operatör karar verir → confidence threshold / fallback / human override

Bu föyün çıktısı **AI Fail-Safe Decision** → Evidence Pack **EP 03 + EP 15** başlığına oturur.